

● 周 瑛, 刘 越, 蔡 俊 (安徽大学管理学院, 安徽 合肥 230601)

基于注意力机制的微博情感分析*

摘 要: [目的/意义] 微博作为人们表达观点的重要平台, 已成为文本情感分析的一个研究热点。文章提出一个基于注意力机制的 LSTM 模型, 以华为 P10 闪存门事件微博相关评论为研究对象, 分析网络用户对该事件的情感趋向, 以验证该模型的有效性。[方法/过程] 引入深度学习理论, 使用基于注意力机制的 LSTM 模型进行情感分析以更好地把握文本中的情感信息, 提升情感分类的成功率。[结果/结论] 基于注意力机制的 LSTM 模型是一个有效的模型, 在分析较长文本的情感特征时更加准确, 比较适合微博这类成段落的文本分析。[局限] 对于颜文字、表情包等非文字信息无法进行处理及无法体现词与词之间的关系。

关键词: 自然语言处理; 情感分析; 情感词; 注意力机制; LSTM 模型

Sentiment Analysis of Micro-blogs Based on Attention Mechanism

Abstract: [Purpose/significance] As an important platform for people to express their views, micro-blog has gradually become a research hotspot of text sentiment analysis. This paper proposes a LSTM model based on attention mechanism, and takes micro-blog comments of Huawei P10 problem as the research objects to analyze the emotional tendency of network users, which further verifies the effectiveness of this model. [Method/process] The paper introduces the depth learning theory, and uses the LSTM model to carry out emotional analysis in order to better grasp the emotional information in the text and enhance the success rate of emotional classification. [Result/conclusion] The LSTM model is effective, which can be reflected in the accurate analysis of the emotional features of longer texts, especially for paragraph texts of micro-blogs. [Limitations] The proposed model cannot deal with Yan text, facial expressions, and other non-text information, as well as reflect the relationship among words.

Keywords: natural language processing; sentiment analysis; emotion terms; attention mechanism; LSTM model

随着开放型信息时代的到来, 微博作为数据共享和信息服务的载体出现在生活中, 已经成为一种大众化服务模式下进行用户信息和观点发布及情感反馈的平台^[1]。根据第 11 届中国网络媒体论坛的数据显示, 我国目前网民数为 4.85 亿, 居世界第一, 其中微博用户已超过 3 亿^[2], 如此巨大的用户基数使得社会热点事件大都是第一时间通过微博爆料而引起全国人民普遍关注的^[3]。微博是以用户关系为纽带建立起来的网络社交平台、手机博客等的集成, 其凭借短小灵活和快速的优点, 受到广大互联网用户的推崇。微博用户通过评论热点事件、书写影评影视观点、描述产品体验等, 产生大量带有情感倾向的文本信息^[4]。据官方数据显示, 截至 2011 年 9 月, 仅新浪微博用户平均每天发布的微博数量就高达一亿多条^[5]。通过对如此海量的数据信息进行情感分析, 可以更好地理解用户的行为, 发现用户的选择偏好及对某一事件的关注程度。例如利用各地区微博中人们的感情变化来分析政府的

举措是否得当, 结果可以为当地政府的决策做指导^[6]。又如利用微博中对上映电影的讨论进行分析, 可以了解电影的热度, 甚至预测票房, 为企业的营销计划做决策等^[7]。因此对微博文本进行情感分析意义重大, 这就促成了微博文本情感分析的快速发展。

1 研究背景

目前, 文本情感分析主要是通过分析文本内容来判断用户所表达的思想观点, 进而判断用户的情感倾向。情感分析自 2002 年被 Yang Bo 提出以来, 经过众多研究者的研究完善后, 获得了很大的发展。如 Turney 等提出采用依赖种子情感词集合, 使用互信息的方法来判别某个短语是否是评价词语; 罗毅等则通过构建二级情感词典, 使用 N-gram 模型获取文本特征进行情感分析; 任远等则是采用支持向量机和 TF-IDF 计算特征项权值来进行情感分析^[4]。但值得注意的是目前国内外这些情感分析方法在英文文本的使用上较为成熟, 在中文文本分析上相较而言处于初步阶段。这主要是由于中文文本的测评资源相对来说匮乏且杂乱。并且相较英文而言, 中文词处理存在着巨大

* 本文为国家社会科学基金项目“大数据环境下情报研究方法论体系研究”的成果之一, 项目编号: 15BTQ045。

的挑战^[8]，主要表现在以下几点：

1) 正确分词难度大，目前无论是在国内还是国外，自然语言处理的基本单位都是单词，因此中文自然语言处理的第一步就是要进行分词。由于中文的一些特性，正确分词的难度很大。而词语分割不当对情感分析的结果影响非常大。例如，“白天下棋”，就有着分割为“白”“天下”“棋”和“白天”“下棋”两种分法。

2) 一词多义现象明显，比如算账，既可以理解为计算账目，也可以理解为与人较量。甚至很多词语具有两层完全相反的含义，如“空穴来风”，既可以指没有事实根据又指有事实根据。这些情况的出现使得传统的词典法和规则法解析情感变得尤为困难。

3) 中国历史悠久，历史上万千典故都被浓缩为四字成语或谚语，一篇引经据典的文章背后往往有几十个故事内涵。还有很多时候列举成语并不是要表达成语通用的解释，而是为了借成语故事中的某人某物进行类比，这就给自然语言处理造成了极大困扰。

上述问题的出现是由于汉语中的词没有分割符（与英语中的词以空格或其他符号分割有本质的差别）、一词多义以及一义多词等原因造成的，这些问题导致了自然语言处理中分词的难度大，这也是目前中文文本处理中遇到的瓶颈问题。再加上由于中文历史源远流长，其字词的含意经过上千年演绎，一直在不断地融入新的含义，这就造成了字词的内涵十分复杂，这些导致了中文的分词的准确度不高，很多对英文适用的方法用在中文上效果都不如尽人意。而分词对于自然语言处理来说是一个预处理的过程，分词的准确度较低，直接影响到后面对文本信息的处理精度。目前，除非中文自然语义理解方面有很大的进展，否则分词的准确度难以提高。这就对文本信息的分析工具和分析结果提出了更高的要求。

基于此，本文为克服传统情感分析方法自身的缺点，基于自然语言处理技术提出一个可以自动搜集微博信息并且分析其情感倾向的系统，以微博热搜事件——华为 P10 手机闪存门为例。通过网络爬虫收集从华为 P10 手机发布当天到爆出闪存问题后 4 天微博中对此事件的评论，并对其进行情感分析。然后结合实际评论情况，验证该模型的有效性，找出递归网络情感分析存在的优缺点，并据此提出实质性改进建议，以期对后期研究工作提供一定的参考。

2 研究模型分析

为了实现对指定主题的网民意见分析，本文使用了 python 程序语言设计了网络爬虫来获取特定微博信息，并训练了一个基于 LSTM 的神经网络模型，该模型带有注意

力机制。使用该模型可以对文本的情感进行极性判断，能给出某主题下根据时间顺序的网民情感状态走向图。

首先选择热点事件——华为 P10 手机闪存门为研究对象，然后通过网络爬虫收集从华为 P10 手机发布当天到爆出闪存问题后 4 天微博中对此事件的评论，最后对其进行情感分析，以根据时间顺序得出网民的情感趋向。

2.1 模型结构及参数设置

微博文本情感极性分析模型的结构共分 5 层：输入层、向量编码层、LSTM 层、注意力层和输出层，具体结构如图 1 所示。

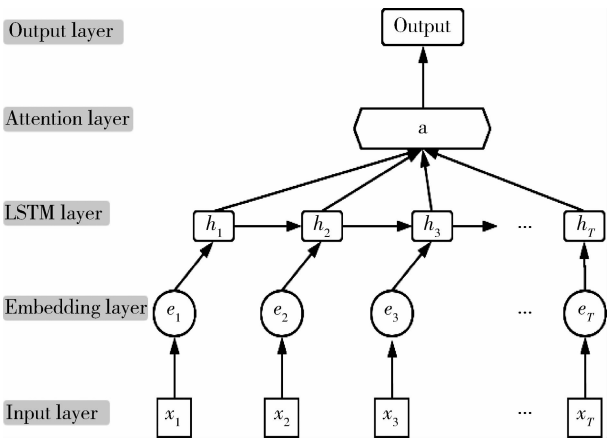


图 1 微博文本情感极性分析模型结构

1) 输入层。即每个需要被分析的微博文本都是一次完整的输入，将其分词后的每个词视为最基本的单位，按顺序向下一层输入。为了方便计算，取单个文本最长值为所有文本的长度。该长度就是 LSTM 层中的时间步数。

2) 向量编码层。这一层主要将输入层文本中的每一个词语映射为一个 64 维的向量，并在随后的训练中进行调整。

3) LSTM 层。本文将 LSTM 装置所在的神经网络层称为 LSTM 层，该层是模型的主要层。LSTM 层内有多个 LSTM 单元，LSTM 单元的个数等于时间步数。如图 2 所示，每个由向量编码层传递过来的向量都会进入一个 LSTM 单元，并在输出该 LSTM 单元的信息后进入下一个时间步的 LSTM 单元。值得注意的是，LSTM 单元主要利用 4 个组件来完成特征提取的功能，其中隐含层神经元数目为 256 个。

4) 注意力层。该层的主要作用是合并 LSTM 层中每一个时间步获取的信息。

5) 输出层。该层将注意力层的输出通过激活函数 tanh 进行情感极性分类，该函数的输出范围是 $[-1, 1]$ ，可以较明显地分开两种情感极性。本模型将负值视为消极情感，非负值视为积极情感。

模型的各个参数设置如下：模型中各权重的初始化值范围为 $[-1, 1]$ 。初始的学习速率为 1，并在每轮整体训练完成后逐渐下降，下降速率为 0.5。训练轮数为 13，每批训练数据的规模为 20。

2.2 词向量的处理

将自然语言做数字化处理，使用数字符号的表示方法作为神经网络的输入，目前较好的方法是采用向量来表示字词句甚至篇章。文本的向量化有多种方式，相对于会造成维数灾难的 one-hot 方法来说，训练一套低维度的词向量来表示单词是一种较好的选择。

本文的模型输入是微博文本，给定一个由多条微博构成的语料库，然后将语料库中的单词去重建立词汇表，所谓的词汇表就是一个中文词汇和数字一一对应的哈希表，建立词汇表的目的是将中文数字化。例如语料库为“今年的牛奶很好喝很甜”，则词汇表就为（1：今年 2：的 3：牛奶 4：很 5：好喝 6：甜），这样每个句子就都可以使用数字来表示，例如“牛奶很好喝”就可以表示为（3，4，5）。

每条微博文本 T 分词后以词语 w 为最小单位， $T = \{w_1, w_2, \dots, w_n\}$ 。在进入神经网络前，每一个词语 w 都会被转化为一个低维的向量 v 。具体做法是将语料库中的所有词语都映射到一个 d 维的向量 e 上去，这样所有的输入词都会组成一个 d 列 $|V|$ 行的矩阵 M ，其中 $|V|$ 是词汇表的长度，词向量矩阵中每一行就是一个词对应的词向量。这样将微博文本转换维向量形式的时候就可以直接根据词汇表中查找矩阵，得出文本的向量表达方式 $T = \{e_1, e_2, \dots, e_n\}$ 。一般情况下，很难将自然语言直接作为输入来训练神经网络，在输入之前通常要对文本进行分词等预处理，主要处理过程如下。

2.3 LSTM 递归网络

LSTM（Long Short Term Memory network，长短期记忆神经网络）是一种特殊的递归神经网络，首次由 S. Hochreiter 和 J. Schmidhuber 在 1997 年提出^[9]，可以带着过去的信息参与对未来的预测中，这种特性使得它非常适合需要利用到过去信息的预测任务中去。LSTM 可以很好地解决长时依赖问题。长时依赖是指当预测点与依赖的相关信息距离比较远的时候，就难以学到相关信息，也就是说当两个相关的核心词相距比较远的时候，前一个词对后面一个词的影响就会消失。一般情况下，常规的递归神经网络不能很好地解决长时依赖，普通的神经网络结构也难以传递相隔较远的信息，LSTM 可以很好地解决这个问题。

LSTM 模型还可以较好地解决传统 RNN 中的梯度消失问题。本文使用的一种模型是根据 Graves 提出的 LSTM 的变体，它的核心思想是通过 3 个“门”来控制信息的增加或删除，基于这种 LSTM 的 RNN 带有 4 个神经网络层，通过这 4 个神经网络层的相互作用使得其能够解决 RNN 模型训练中的长期依赖问题。基于注意力机制的 LSTM 模型如图 2 所示，注意力机制通过 Attention 模块实现。

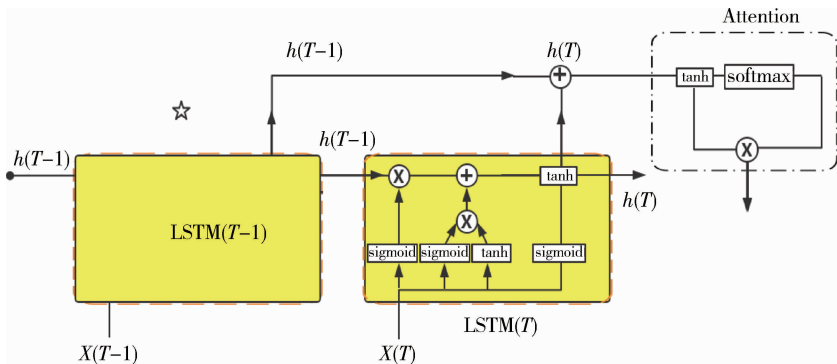


图 2 基于注意力机制的 LSTM

在图 2 所示模型中，带有 LSTM 单元的 RNN 有 4 个组件。当信息首先来到 LSTM 时，将分别通过 3 个“门”装置来实现信息的丢弃与更新。“遗忘门”将决定有哪些信息被丢弃。它的计算结果是一个 0~1 之间的数字。1 表示“完全保留”，而 0 则表示“完全抛弃”。

$$f_t = \text{sigmoid}(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

由“输入门”来决定哪些信息会被加入进来。

$$i_t = \text{sigmoid}(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3)$$

最后通过“输出门”来实现信息的更新。

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

在这个模型中，对于前传递而言，通过输入门的学习来决定何时让激活传入存储单元，而通过输出门的学习则决定了何时让激活传出存储单元。相应的，对于后传递，通过输出门的学习决定了何时让错误流入存储单元，而通过输入门的学习决定了何时让错误流出存储单元，并传到网络的其余部分。

2.4 注意力机制的分类激活

注意力机制（Attention Mechanism）最早是于 20 世纪 90 年代中期在视觉图像领域提出来的，但是真正被研究者重视则是 Google Mind 团队 2014 年发表的一篇论文^[10]，他们研究的动机受到人类注意力机制的启发。人们在进行观察图像的时候，并不是一次就把整幅图像的每个位置像素都看过，大多是根据需求将注意力集中到图像的特定部分。而且人类会根据之前观察的图像学习到未来要观察图像注意力应该集中的位置。根据人类学习的这个特点，他

们在递归神经网络模型上使用了注意力机制来进行图像分类。随后 Bahdana 在机器翻译任务中使用了基于注意力机制的 encode-decode^[11]。这篇论文在自然语言处理领域是第一个使用注意力机制进行工作的。他们把注意力机制用到了神经网络机器翻译上，神经网络机器翻译其实就是一个典型的序列到序列模型，也是一个编码到解码的模型，传统的神经网络机器翻译使用两个递归神经网络，一个递归神经网络对源语言进行编码，将源语言编码到一个固定维度的中间向量，然后在使用一个递归神经网络进行解码翻译到目标语言，而该论文将注意力机制加入到本文的模型中，使得模型在处理情感相关信息时可以更敏感。如图 2 所示的结构，定义 H 为 LSTM 层 T 个时间步的输出总和。

$$M = \tanh(H) \tag{5}$$

$$\alpha = \text{softmax}(w^T M) \tag{6}$$

$$\gamma = H\alpha^T \tag{7}$$

在获取了注意力层的输出值 γ 之后，由激活函数 \tanh 函数来将结果映射到 $[-1, 1]$ 之间。对于 $[-1, 1]$ 之间的数据，本文定义 $[-1, 0]$ 区间的数据为“消极”，定义 $(0, 1]$ 之间的数据为“积极”。

3 实验过程与结果分析

3.1 实验环境设计

本文中的实验环境包括硬件配置和软件运行环境。硬件配置和操作系统的设置结果见表 1。软件运行环境中除了基本的操作系统以外，本文还使用了 Tensorflow 来作为模型的训练工具。Tensorflow 是 Google 开发的人工智能学习系统，作为一款完全开源的深度学习工具，其一发布就获得了极大的关注。Tensorflow 用张量（Tensor）表示数据，用图（Graph）表示神经网络，用流（Flow）表示数据计算流程。Tensorflow 不仅简单易用，而且它的功能还十分强大，主流的算法模型都能实现，而且可以有效利用 GPU 来训练模型。而实验的测试数据则以华为 p10 手机为例，选取华为手机发布日期 2017 年 2 月 26 日到 4 月 20 日间的微博进行数据处理，然后使用本文训练完成的模型对文本进行情感分析，最后绘制情感变化曲线。

表 1 实验环境	
操作系统	Ubuntu16. 04
CPU	Intel (R) Core (TM) i5-3230M CPU@2. 60 GHz (4 CPUs), ~2. 6 GHz
内存	8192 MB RAM
GPU	NVIDIA GeForce GT 750M

3.2 实验数据准备与处理

本文的实验数据包括训练数据和测试数据两部分。对

于训练数据来说，首先进行实验数据准备，将训练数据进行分词后，将数据标记为积极语料和消极语料两大类。积极和消极语料的对比例子如表 2 所示。

表 2 积极语料和消极语料对比	
消极	积极
蒙牛又出来丢人了	蒙牛新出的枕奶很好喝，有进步
蒙牛早餐奶剧难喝	喜欢喝蒙牛这个牌子的牛奶，真的很甜

从表 2 中就可以看到 coae2014 测评语料中消极与积极语料的对比，例如“蒙牛又出来丢人了”是消极语料，而类似“蒙牛新出的枕奶很好喝，有进步”是积极语料。本文采用 coae2014 测评语料共 1836 条语料作为训练数据，其中 834 条消极语料，1002 条积极语料。

其次要进行语料处理工作。前期数据准备工作之后，以空格代替中文以外的表情符号、标点符号等，然后使用结巴分词工具将语料分割为以词为最小单位的文本，统计文本中所有的单词。为了加快训练速度，截取出现频率最多的 80% 词汇，建立字典将其进行数字化，使每个词和一个数字互相对应，以方便训练模型的输入。在随后的模型训练中这些单词对应的向量也会被优化。然后将数据投入神经网络，使用反向传播来优化。通过训练，最后得出模型的所有参数。

而对于测试数据，本文使用网络爬虫技术抓取了新浪微博关于华为 P10 手机的微博评论作为测试数据。对于这些要测试的数据，首先去除文本中的图片、颜文字，以及无意义文本比如链接，并将需要分析的微博文本进行文本预处理。这包括去除中文以外的符号图片，通过字典将其数学化。实验中采用结巴分词作为主要分词方法。利用结巴分词中上万条词条资源，基于 Trie 树结构的扫描可以实现高效分词。此外基于微博中网络语言特性而添加的词库也进一步加强了分词的效果。对于未登录词，结巴分词也有基于 HMM 模型的成词能力。通过前面建立的字典将词进行数字化，用数字和词一一对应。例如 [由于 存在 闪存 混用 等问题 华为 P10 可谓 是目前 最受 争议的 手机 了] 将其数学化之后就成为 [12, 34, 56, 1123, 355, 356, 567, 678, 234, 78, 64, 78, 24, 678, 965, 456, 1242]。将每个单词映射成 50 维的随机向量，数值范围在 0~1 之间，这时向量不含任何意义。然后将处理过的文本词向量输入已经训练好的模型，利用训练所得到的参数进行测试，最后通过 \tanh 激活函数将其输出结果分散到 $-1 \sim 1$ 之间。本文选择 $[-1, 0]$ 的文本为负向情感，选择 $[0, 1]$ 的文本为正向情感。

3.3 实验结果分析

通过下述图 3 的实验结果可以看出，微博关于华为 P10 的满意度随着时间的变化而变化，从第一天发布会开

始，满意度上升，然后一直稳定在高满意度状态，但是随着缺点被暴露出来，满意度逐渐下降，到了第 50 天，微博上大规模爆出闪存问题，使得用户满意度急剧下降。




图3 华为 P10 闪存门事件模型情感分析结果

而事实上，通过微博具体评论不难发现，华为 P10 手机带着颜值高、配置好、摄影强等的光环出现，在发布会当天受到网友一致好评。并且随着宣传力度的不断加大，在发布会后的 30 多天内微博网友对华为 P10 手机的满意度更是逐渐上升，基本实现零差评，且满意度居高不下。但是在发布会结束 35 天后，由于华为 P10 在屏幕方面没有疏油层及其屏幕的材质方面存在的问题，导致网友对华为 P10 手机的满意度稍有下降，但这两个事件并没有掀起多大的波澜，翻看微博评论不难发现，网友对华为 P10 手机仍然是比较满意的。并且随着华为官方及时的澄清解释，之后网友的满意度还稍有上升趋势。但是在发布会结束的 50 天左右，华为 P10 的闪存问题被网友曝光，在各大交流平台上，关于华为 P10 闪存的相关内容增加，更多的用户开始关注这个问题。并且由于华为官方对此事并未做出明确的解释，所有的答复都是遮遮掩掩、欲盖弥彰、顾左右而言他，相关措施也是只闻其声而已，导致微博网友对华为 P10 手机的满意度大幅度下降，网络上出现网友的大量吐槽，绝大多数网友对华为 P10 手机表现出了不满情绪。

通过上述分析，将模型预测结果与实际结果相比较，得出如表 3 所示结果。

表3 LSTM 模型文本分析结果与实际微博评论结果对比

	发布会当天	发布会后 35 天	发布会后 50 天
模型处理结果	满意度为 0.9	满意度为 0.78	满意度为 0.41
实际结果	零差评，满意度接近于 1	较满意，满意度约为 0.7	不满意，满意度约为 0.3

通过表 3 可以看出，本文提出的 LSTM 递归网络模型对微博文本的处理结果与事实基本相符，据此可以判断该模型可以在一定程度上通过情感分析来判断用户的情感走向。

4 结论

近年来，深度学习不仅在图像处理方面取得了巨大的突破，在对自然语言处理的许多任务上也有着很好的效果，成为专家学者的热门研究方向。本文根据深度学习原理提出的基于注意力机制的 LSTM 递归网络分析模型，与传统自然语言处理技术中的一些难题有较大的改进。传统方法在一词多义、熟语理解等问题上面面临的困境是无法根据语境来判断，而通过在模型中增加注意力机制的 LSTM 模型在为某一文本寻找情感关系时，并不只单单根据某一词语来判断情感极性，而是会根据上下文信息来综合判断。并且注意力机制可以帮助模型选择恰当的上下文，过滤其他无关信息。这使得本文提出的模型具有如下优点：

- 1) 从分析结果可以看出，本文模型中注意力机制的应用使得该模型在处理情感相关信息时更加敏感，有利于帮助模型更好地捕获情感信息，减小误差，增加分析结果的准确度，从而增强了模型的情感分析能力。
- 2) LSTM 模型在序列建模上是一个有效的模型，其通过“输入门”“遗忘门”和“输出门”这 3 个“门”的结果来控制信息的增加或者删除，能够有效地解决 RNN 模型训练中的长期依赖问题。因此在分析较长文本的情感特征时更加准确，适合微博这类成段落的文本分析。

但是，本文中的情感分类方法还有很大的改进空间，在以后的研究中可从以下两个方面对该模型进行改进，以提高分析结果的精确度。

- 1) 文本数据处理方面的改进。本文在对数据处理时删除了除文字外的所有信息，仅仅是对文字信息进行了处理。但是在目前网络用语中，颜文字、表情包等信息往往带有比文字更强烈的情感色彩，而且这些都是进行文本情感分析的有利信息。因此如果能将这些数据转化为一定的数学符号进行处理，将能够提高文本情感分析的准确度。
- 2) 对词向量进行预处理，使用更合适的词向量。本文词向量的初始化是随机的，在训练中根据反向传播原理来优化的。它的一个缺点就是不能体现词与词之间的关系。在以后的研究工作中可以对词向量进行预训练，通过 Word2Vec 方法训练的词向量可以较好地体现出词与词之间的关系。再将经过预处理的词向量作为网络的输入，对提高情感分析的准确率有着很大的作用。

综上所述，由于使用了注意力机制，LSTM 在处理与

文本情感相关的信息时更加准确,有着很好的情感分析能力;同时,由于 LSTM 模型在序列建模上的优势,比较适合对较长文本的情感特征的分析,在分析微博类型的文本中的情感特征时表现出了很强的分析能力。在今后的工作中,通过增加对颜文字、表情包等非文本信息的处理以及对词向量的预处理这两项工作,可以进一步提高 LSTM 模型在微博情感分析中的能力,对于更好地预判用户的情感状态,提早做出各种应对预案有很大的帮助。□

参考文献

[1] 唐晓波,严承希.基于旋进原则和支持向量机的文本情感分析研究[J].情报理论与实践,2013,36(1):98-103,93.

[2] 吴青林,周天宏.基于话题聚类及情感强度的中文微博舆情分析[J].情报理论与实践,2016,39(1):109-112.

[3] 中国网络媒体论坛[EB/OL].(2011-11-22)[2017-06-20].
http://www.chinaz.com.

[4] 冯兴杰,张志伟,史金钊.基于卷积神经网络和注意力模型的文本情感分析[J].计算机应用研究,2018(5):1-2.

[5] 刘楠.面向微博短文本的情感分析研究[D].武汉:武汉大学,2013.

[6] SEKI Y. Use of twitter for analysis of public sentiment for improvement of local government service [C] //IEEE International Conference on Smart Computing. IEEE, 2016: 1-3.

(上接第72页)

[5] 刘丽敏,孙东亮,等.社会网络中隐性知识交流研究[J].情报理论与实践,2015(11):30-35,29.

[6] 黄微,高俊峰,等.基于社会网络分析的隐性知识推送服务方法研究[J].现代图书情报技术,2014(2):48-54.

[7] 潘玮,王伟,等.社会网络视角下企业内部隐性知识共享效率的测度方法研究[J].情报科学,2014(8):134-139.

[8] 何水儿,张华,耿丽君.社会网络与个体特征对隐性知识共享的影响[J].科技管理研究,2013(24):156-161,166.

[9] 姜鑫.基于社会网络分析的组织非正式网络内隐性知识共享及其实证研究[J].情报理论与实践,2012(2):68-71,91.

[10] 张嵩,张旭.基于社会网络的隐性知识转移机制实证研究——以IT行业为例[J].图书情报工作,2010(22):102-106,65.

[11] 王嵩,田军,王刊良.创新团队内的隐性知识共享——社会网络分析视角[J].科技管理研究,2010(1):208-210.

[12] ZHANG L Y, HE J. Critical factors affecting tacit-knowledge sharing within the integrated project team [J]. Journal of Management in Engineering, 2016, 32(2).

[13] 李国彦,李南.创业社会网络中隐性知识转移激励模型研究——代理人市场——声誉理论视角的探索[J].科技进步

[7] 史伟,王洪伟,何绍义.基于微博情感分析的电影票房预测研究[J].华中师范大学学报:自然科学版,2015,49(1):66-72.

[8] 谢丽星,周明,孙茂松.基于层次结构的多策略中文微博情感分析和特征抽取[J].中文信息学报,2012,26(1):73-83.

[9] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9(8):1735-1780.

[10] MNH V, HEES N, GRAVES A, et al. Recurrent models of visual attention [C]. Advances in Neural Information Processing Systems 27 (NIPS 2014), 2014: 2204-2212.

[11] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate [J]. Computer Science, 2014(5).

作者简介:周瑛,女,1968年生,教授,博士生导师,发表论文30余篇。研究方向:人工智能,信息检索结果的可视化,信息检索系统的评价等。**刘越**,女,1992生,硕士生。研究方向:信息检索系统的评价。通讯作者。**蔡俊**,男,1988年生,硕士生。研究方向:数据挖掘。

作者贡献声明:周瑛,提出思路,设计实验方案,论文最终版本修订。**刘越**,进行实验,论文起草。**蔡俊**,搜集、分析数据,协助实验。

录用日期:2017-09-01

与对策,2016(7):139-143.

[14] 王平.基于社会网络分析的组织隐性知识共享研究[J].情报资料工作,2006(2):102-107.

[15] POLANYI M. Personal knowledge: towards a post-critical philosophy [M]. London: Routledge & Kegan Paul Ltd, 1962.

[16] GRANOVETTER M S. The strength of weak ties [J]. The American Journal of Sociology, 1973, 78(6):1360-1380.

[17] 北京美兰德信息咨询有限公司[EB/OL]. [2017-05-20].
http://www.yjbys.com.

[18] LU H L, YANG C J. Job rotation: an effective tool to transfer the tacit knowledge within an enterprise [J]. Journal of Human Resource and Sustainability Studies, 2015, 3(1):34-40.

[19] 陈真.知识型企业的隐性知识共享及其影响因素分析[J].上海商学院学报,2010(3):53-56.

[20] 马德辉,包昌火.企业知识网络能力及其模型建构初探[J].情报杂志,2008(3):459-467.

[21] 龙莎,葛新权.促进知识管理中隐性知识的显性化[J].北京机械工业学院学报,2008(1):70-72.

作者简介:徐芳,男,1980年生,博士,博士后,副教授。研究方向:竞争情报与危机预警,数字图书馆用户体验与交互。**瞿静**,女,1995年生。研究方向:知识管理,社交媒体。

录用日期:2017-08-17